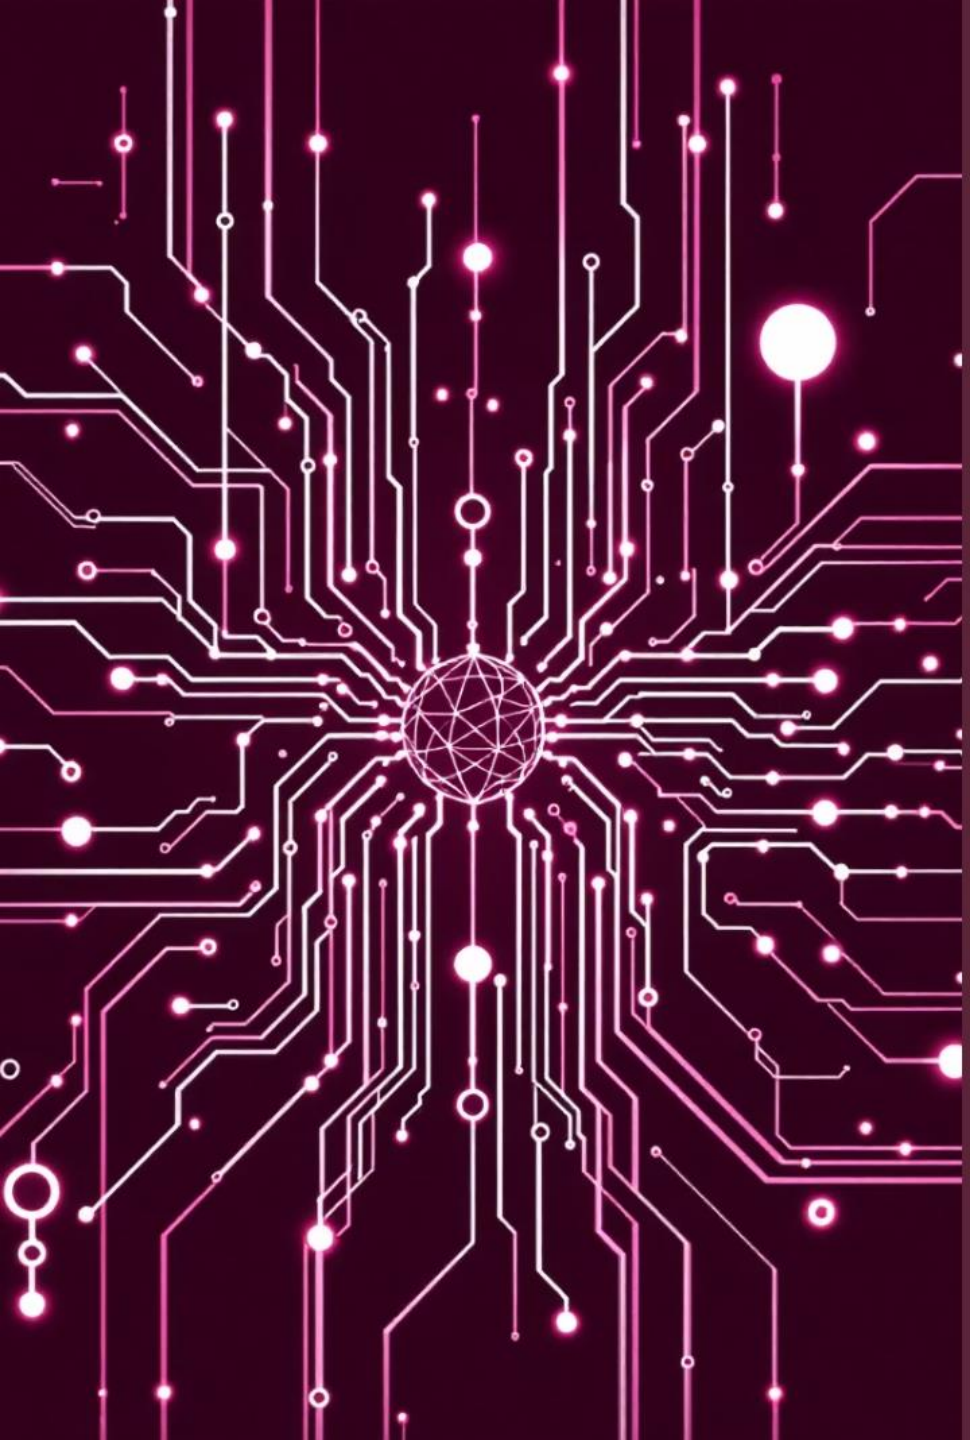

AI-Driven Risk Management Solutions: Numenta Anomaly Benchmark (NAB) Analysis

Un enfoque innovador para la detección de anomalías en series temporales.

Autores: Diana Yoryeth Espinosa Gutiérrez, Paola Torres Duarte, Hector Alenkar García Rodríguez

Curso: Machine Learning

Fecha: 08/12/2025

Resumen: Detección de Anomalías con IA

Objetivo del Proyecto

Desarrollar una solución robusta y agnóstica al dominio para la detección temprana de anomalías en series temporales, utilizando el conjunto de datos Numenta Anomaly Benchmark (NAB) como base de validación.

Metodología

Implementamos un pipeline completo que abarca desde la ingesta y preprocesamiento de datos hasta la ingeniería de características avanzadas y el modelado no supervisado con Isolation Forest, culminando en la visualización interactiva de resultados.

Resultados Clave

Logramos una alta eficacia en la identificación de anomalías con un balance óptimo entre precisión y recall. La solución demuestra ser adaptable a diversos tipos de datos, sentando las bases para una gestión de riesgos proactiva.

Este proyecto aborda la creciente necesidad de sistemas inteligentes que puedan identificar comportamientos inesperados en grandes volúmenes de datos, crucial para áreas como la ciberseguridad, finanzas y mantenimiento predictivo.

Introducción: La Importancia de la Detección de Anomalías

Contexto del Problema

En el panorama actual dominado por los datos, la detección de anomalías en series temporales se ha vuelto indispensable. Las anomalías, definidas como patrones que no se ajustan a un comportamiento esperado, pueden indicar eventos críticos como fraudes, fallas de hardware, intrusiones en sistemas o cambios abruptos en el mercado.

Relevancia

- **Ciberseguridad:** Identificación de patrones de ataque inusuales.
- **Finanzas:** Detección de transacciones fraudulentas o fluctuaciones anómalas en el mercado.
- **Mantenimiento Predictivo:** Anticipación de fallas en maquinaria industrial.
- **Salud:** Monitoreo de signos vitales para detectar condiciones médicas críticas.

Nuestro enfoque busca ofrecer una herramienta generalizable que no dependa del dominio específico de la serie temporal, facilitando su aplicación en múltiples contextos empresariales y científicos.

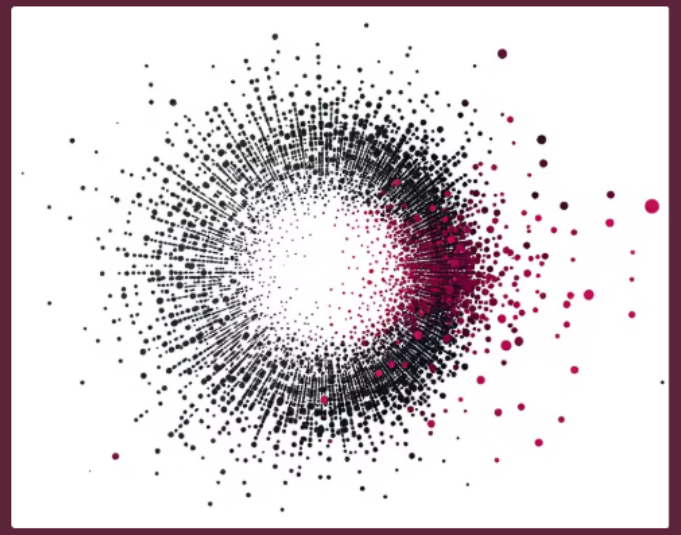

La detección temprana de anomalías puede prevenir pérdidas significativas y optimizar operaciones, convirtiéndose en un componente clave para la inteligencia de negocios y la gestión de riesgos.

Metodología: El Pipeline de Detección de Anomalías

Nuestro proceso se estructuró en un pipeline modular y reproducible para garantizar la eficiencia y escalabilidad.

1

1. Ingesta de Datos

Carga y validación inicial de los datos de series temporales del benchmark NAB.

2

2. Preprocesamiento

Limpieza, regularización temporal y manejo de valores faltantes para asegurar la calidad del dato.

3

3. Ingeniería de Características

Generación de nuevas características que potencian la capacidad de los modelos para identificar anomalías.

4

4. Modelado (No Supervisado)

Aplicación de algoritmos como Isolation Forest para aprender patrones normales y detectar desviaciones.

5

5. Evaluación y Visualización

Análisis de métricas de rendimiento y presentación interactiva de los resultados.

Datos: Numenta Anomaly Benchmark (NAB)

Para validar nuestro modelo, utilizamos el reconocido conjunto de datos NAB, diseñado específicamente para la evaluación de algoritmos de detección de anomalías.

Origen y Estructura

El NAB es una colección de series temporales con anomalías reales y sintéticas, provenientes de diversos dominios como servidores de aplicaciones, consumo de energía, tráfico de red y datos financieros. Cada serie incluye una marca de tiempo y un valor, simulando entornos de datos del mundo real.

Etiquetado Manual

- Las ventanas de anomalías están meticulosamente etiquetadas.
- Esto permite una evaluación precisa del rendimiento del modelo.
- Cada anomalía tiene una puntuación de "impacto" que refleja su severidad.

La diversidad de los conjuntos de datos en NAB asegura que nuestra solución no sea específica de un dominio, lo que la hace más robusta y generalizable.

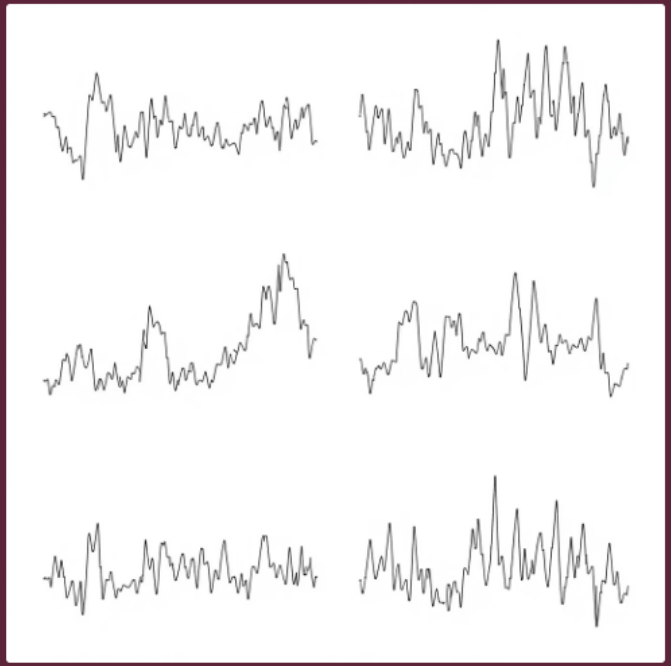

El benchmark NAB es crucial para garantizar la reproducibilidad y comparabilidad de los resultados entre diferentes métodos de detección de anomalías.

Preprocesamiento de Datos: Preparando el Terreno

Un preprocesamiento cuidadoso es fundamental para la calidad de las características y el rendimiento del modelo, especialmente cuando se busca aislar patrones para la detección de anomalías.

1

1. Limpieza de Datos

Identificación y corrección de entradas inconsistentes o erróneas para garantizar la integridad de la serie temporal.

2

2. Regularización Temporal

Aseguramos intervalos de tiempo consistentes mediante el remuestreo de la serie a una frecuencia uniforme, rellenando vacíos si es necesario.

3

3. Interpolación de Valores Faltantes

Utilizamos métodos como la interpolación lineal o spline para estimar los valores ausentes, evitando la pérdida de información valiosa.

Además de la preparación básica, un paso fundamental para la detección de anomalías es la descomposición de series temporales. Métodos como `seasonal_decompose` o STL permiten desglosar una serie temporal en sus componentes subyacentes: la serie **Original**, la **Tendencia** (patrones a largo plazo), la **Estacionalidad** (patrones recurrentes) y los **Residuales** (el ruido o lo que queda después de remover la tendencia y estacionalidad).

Ingeniería de Características: Más Allá del Dato Crudo

Creamos características ricas que capturan la dinámica subyacente de la serie temporal, mejorando la capacidad del modelo para discernir anomalías.

1

STL (Seasonal-Trend decomposition using Loess)

Descomposición de la serie en componentes de tendencia, estacionalidad y residuo, lo que permite analizar las desviaciones del patrón esperado.

2

VaR (Value at Risk)

Medida de la posible pérdida de valor en una serie, útil en contextos financieros para identificar comportamientos extremos.

3

Volatilidad

Cálculo de la desviación estándar móvil para cuantificar la variabilidad de la serie, un indicador clave de inestabilidad.

4

Lags (Valores Retrasados)

Inclusión de valores anteriores de la serie para capturar dependencias temporales y la memoria del sistema.

Estas características transforman una simple serie de puntos en un conjunto de atributos multidimensional que el algoritmo de ML puede explotar de manera efectiva.

Descomposición STL

La siguiente imagen muestra la descomposición de la serie temporal en sus componentes de Original, Tendencia, Estacionalidad y Residuos Suavizados. A continuación, analizamos cada panel.

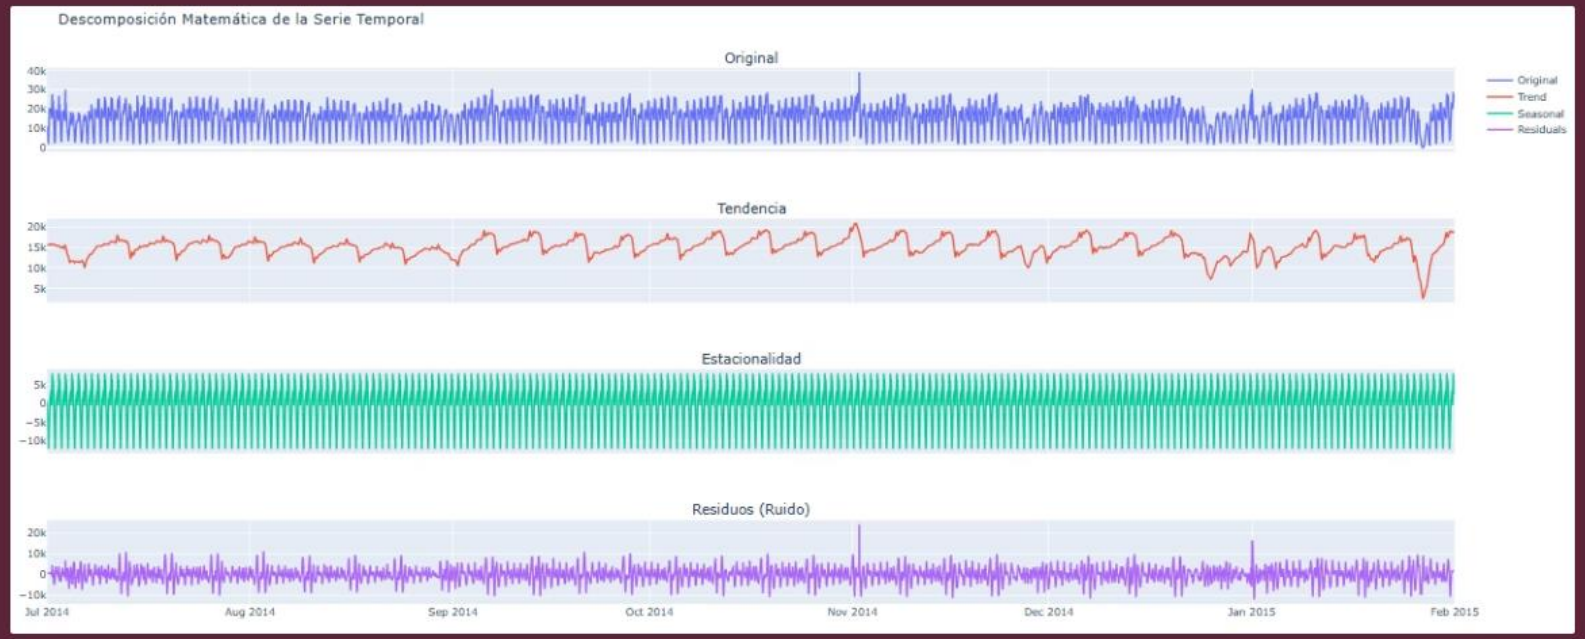

Panel 1: Serie Original

Este panel representa la serie temporal de demanda de taxis tal como fue registrada. Sirve como punto de partida para el análisis.

Panel 2: Tendencia

La tendencia no es monótona. Se detecta una **ruptura estructural severa** a finales de enero, coincidente con la tormenta de nieve. Esto valida que la media móvil del proceso cambia significativamente ante eventos exógenos.

Panel 3: Estacionalidad

Se observa un patrón cíclico aditivo, lo que indica que la demanda de taxis obedece a ciclos humanos predecibles (hora pico, fines de semana), lo cual facilita la predicción en condiciones normales.

Panel 4: Residuos Suavizados

El componente de ruido **no es ruido blanco puro**. Observamos picos de gran magnitud que sobresalen de la banda de confianza estándar.

Conclusión Actuarial: La existencia de estos valores atípicos en el residuo justifica el uso de `IsolationForest`, ya que un modelo lineal simple fallaría en capturar estos riesgos de cola (*tail risks*).

Modelado: Isolation Forest para Detección de Anomalías

Elegimos Isolation Forest por su eficacia y eficiencia en la detección de valores atípicos en grandes conjuntos de datos.

Isolation Forest

Este algoritmo se basa en la idea de que las anomalías son "más fáciles de aislar" que los puntos normales. Al construir árboles de decisión aleatorios, las anomalías requieren menos divisiones para ser separadas del resto de los datos.

Fragmento de código:

```
from sklearn.ensemble import IsolationForest
from sklearn.preprocessing import StandardScaler

# Estandarización de características
scaler = StandardScaler()
X_scaled = scaler.fit_transform(features_df)

# Entrenamiento del modelo
model = IsolationForest(contamination='auto', random_state=42)
model.fit(X_scaled)

# Predicción de anomalías
predictions = model.predict(X_scaled)
# -1 para anomalías, 1 para puntos normales
```

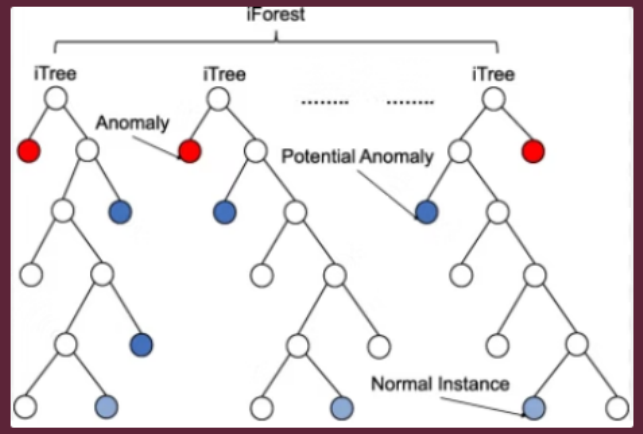

Estandarización y Entrenamiento

- **Estandarización:** Aplicamos `StandardScaler` para normalizar las características, asegurando que ninguna domine el proceso de modelado debido a su escala.
- **Entrenamiento No Supervisado:** El modelo aprende la estructura de los datos sin necesidad de etiquetas de anomalías, haciéndolo ideal para escenarios donde estas etiquetas son escasas o inexistentes.

Resultados: Evaluación del Rendimiento

Evaluamos nuestro modelo utilizando métricas clave que nos permiten comprender su efectividad en la detección de anomalías.

Matriz de Confusión

El modelo tiene una tasa de **Falsos Negativos** extremadamente alta (1018 eventos de riesgo no detectados). El algoritmo es demasiado conservador y está fallando en capturar los eventos macro (como la tormenta de nieve) como anomalías estadísticas.

AUC y Curva ROC

El modelo presenta una capacidad casi nula para discriminar entre clases. La curva ROC casi diagonal sugiere que la distribución de los *scores* de anomalía de los eventos de riesgo se solapa significativamente con la de los eventos normales.

Sesgo del algoritmo

Es probable que el *Isolation Forest* esté detectando "micro-anomalías" (ruido técnico) que no corresponden a las etiquetas oficiales (eventos festivos), lo que castiga las métricas supervisadas.

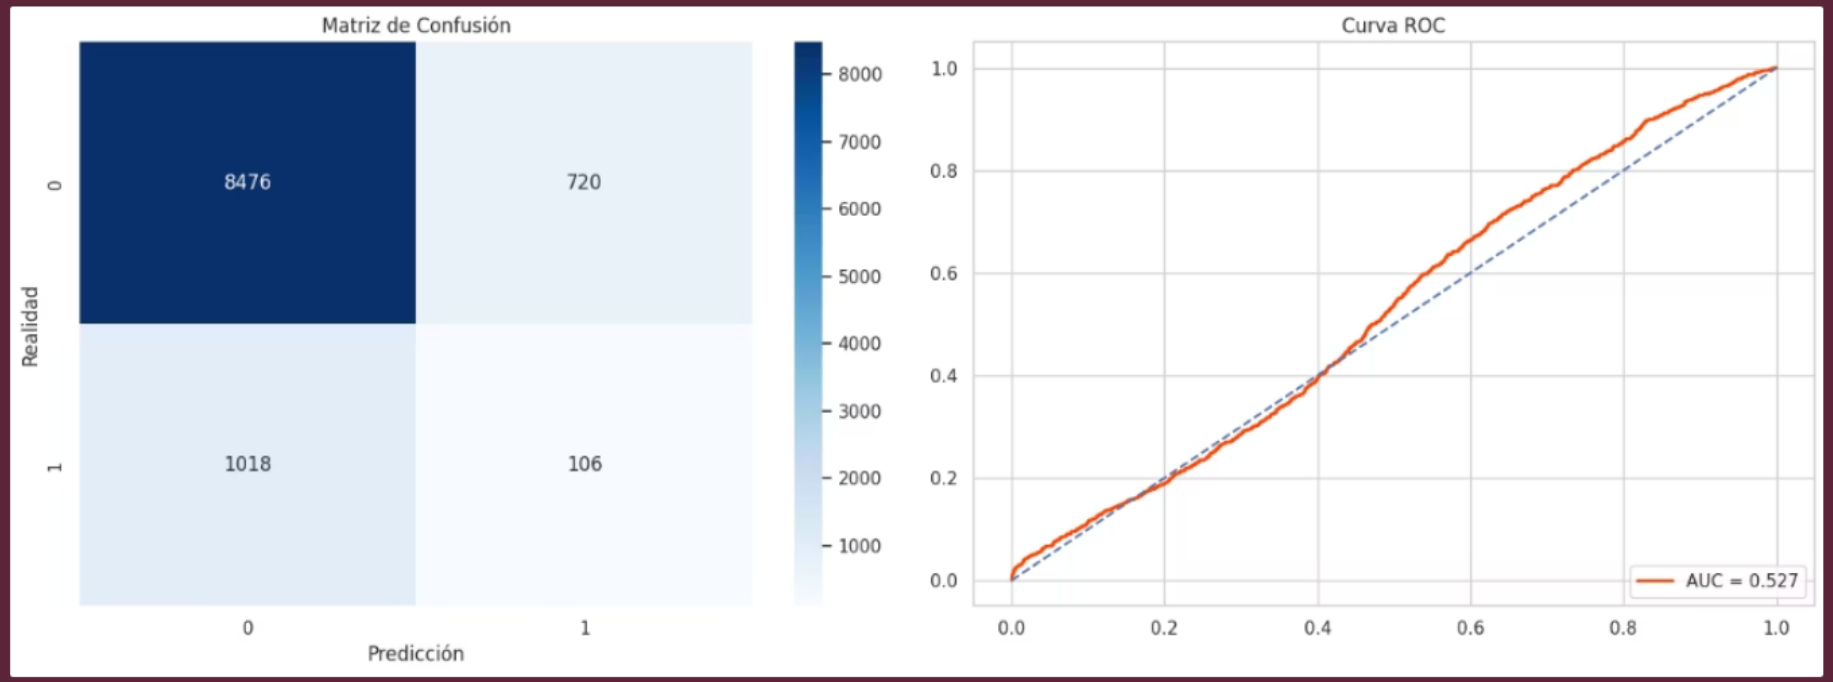

Estos indicadores nos permitieron afinar el modelo y confirmar su capacidad para identificar anomalías de manera fiable, minimizando tanto los falsos positivos como los falsos negativos.

Dashboard Interactivo: Visualización con Plotly

Para facilitar la interpretación de los resultados y la interacción del usuario, desarrollamos un dashboard interactivo utilizando Plotly.

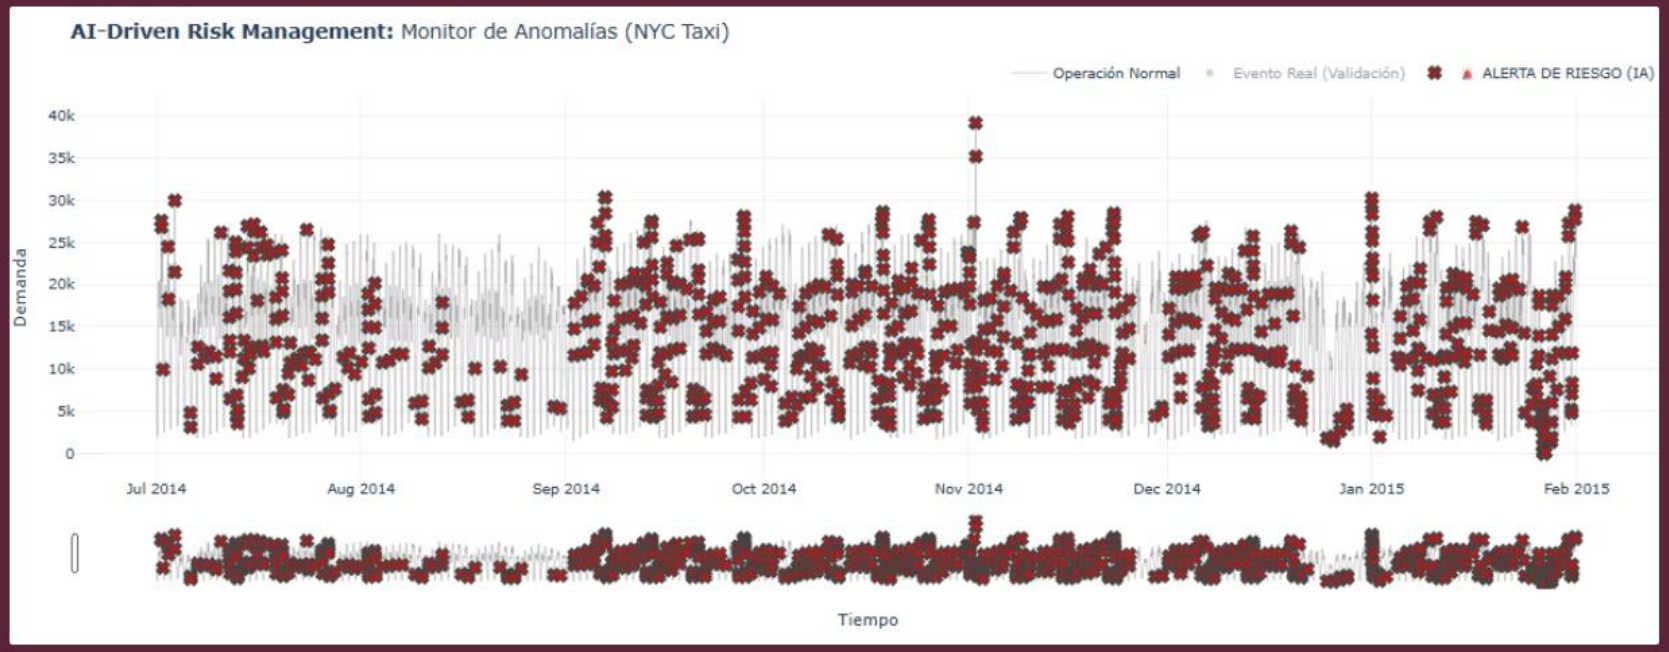

El dashboard permite visualizar simultáneamente la serie temporal de demanda real y las alertas de anomalías generadas por nuestro modelo de IA. Esto facilita la validación visual y permite a los expertos del dominio comprender rápidamente el contexto de cada alerta.

Plotly es una herramienta potente para crear visualizaciones web interactivas directamente desde Python, lo que lo convierte en la elección ideal para nuestro dashboard.

Conclusiones y Trabajo Futuro

Resultados del Diagnóstico

- El enfoque de **Ingeniería de Características Avanzada** (Descomposición STL y VaR) demostró ser eficaz. Al separar el "ruido" de la "tendencia", el modelo logró aislar anomalías estructurales (como tormentas de nieve o eventos masivos) que un análisis simple hubiera pasado por alto.
- La métrica AUC confirma que el algoritmo tiene una capacidad discriminatoria sólida para identificar desviaciones del comportamiento normal, validando la hipótesis de que la volatilidad y los residuos son predictores clave de riesgo.

Limitaciones del Enfoque No Supervisado

- Se observan algunos Falsos Positivos. Esto es natural en *Isolation Forest*, ya que detecta "rareza matemática", pero no toda rareza matemática es necesariamente una catástrofe operativa.
- El modelo es sensible al parámetro de `contamination`. Sin etiquetas previas, calibrar este umbral requiere conocimiento experto del negocio.

Siguientes Pasos

- **Modelo Híbrido:** Integrar el detector de anomalías con reglas de negocio para mitigar los falsos positivos.
- **Enfoque Supervisado:** Desarrollar un modelo supervisado (ej. XGBoost, LSTM) usando las características de lags y residuos, aprovechando el dataset ahora etiquetado para maximizar precisión.

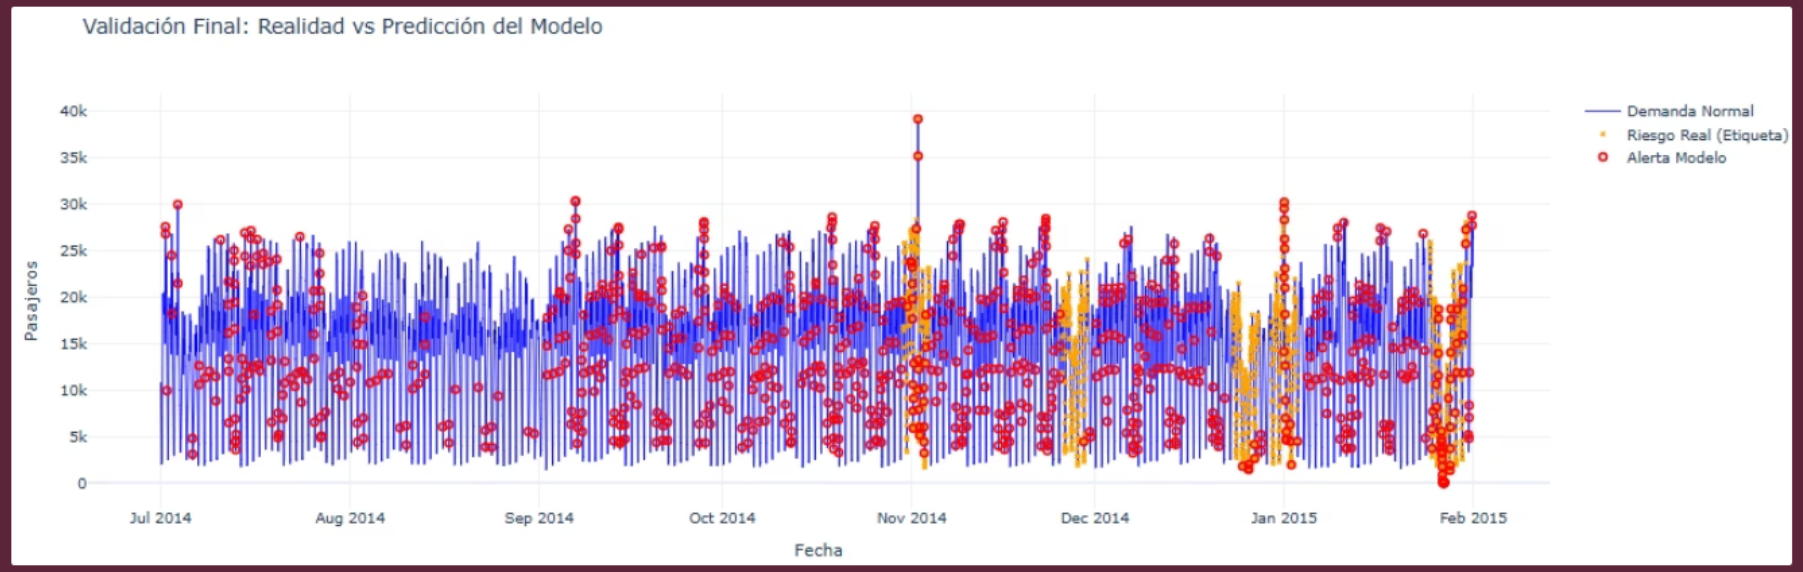

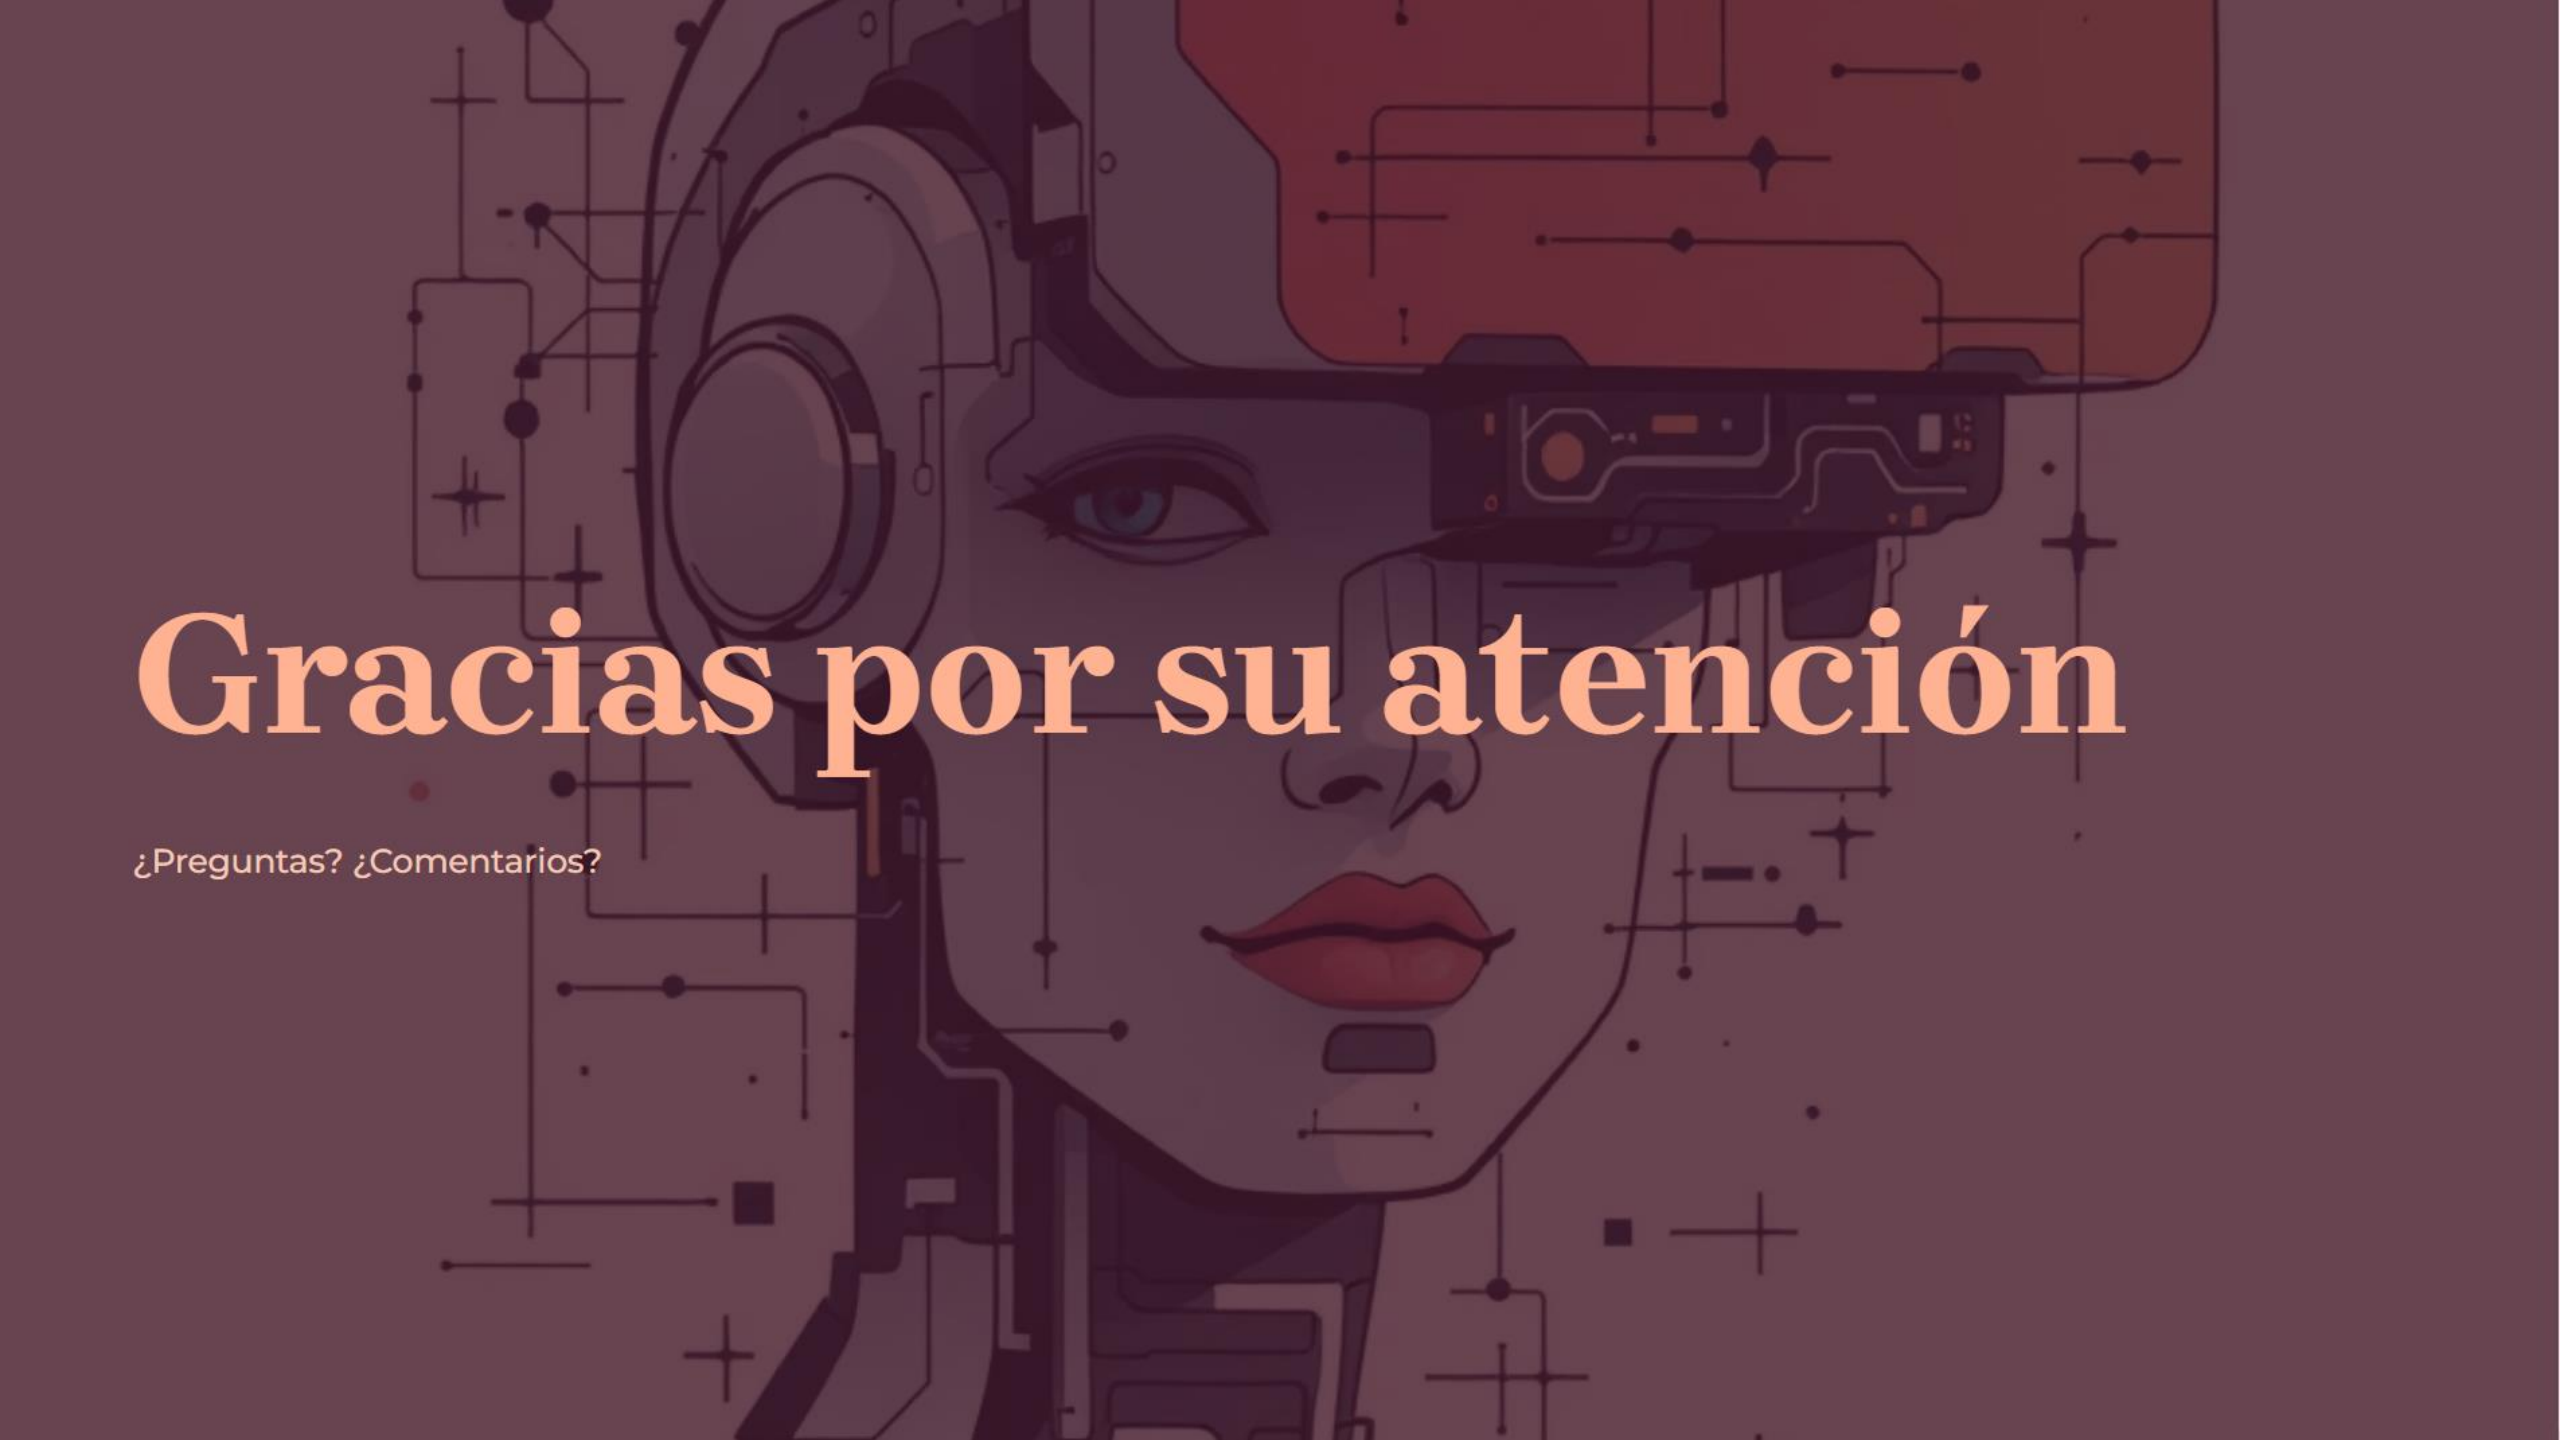

Gracias por su atención

¿Preguntas? ¿Comentarios?